

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Engenharia Elétrica

Giovanni Aurelio

Previsão de Emissões de CO₂ de Usinas Termelétricas Nacionais
utilizando Redes Neurais Artificiais

São Carlos
2026

Giovanni Aurelio

**Previsão de Emissões de CO₂ de Usinas Termelétricas
Nacionais utilizando Redes Neurais Artificiais**

Projeto de monografia de conclusão de curso apresentado ao Curso de Engenharia Elétrica da Universidade Federal de São Carlos como parte dos requisitos necessários para a obtenção do grau de Engenheiro Eletricista.

Orientador: Prof. Dr. Guilherme Guimarães Lage

São Carlos
2026

Dedico este trabalho a todos que me ajudaram a superar os desafios, em especial, os meus colegas da turma Elétrica 019. Sem vocês, tudo seria mais difícil.

Agradecimentos

Agradeço a meu pai, minha mãe.

"Nós sempre nos definimos pela capacidade de superar o impossível."
(Joseph Cooper)

Resumo

Aurelio, Giovanni, **Previsão de Emissões de CO₂ de Usinas Termelétricas Nacionais utilizando Redes Neurais Artificiais**. Trabalho de Conclusão de Curso (Graduação em Engenharia Elétrica). Centro de Ciências Exatas e de Tecnologia, Universidade Federal de São Carlos. 53 p. São Carlos, 2026.

Embora a maior parte da energia elétrica no Brasil provenha de usinas hidroelétricas, as termoeletricas são fundamentais para a segurança energética nacional. No entanto, com as mudanças climáticas causadas pelas emissões de CO₂ de diversos setores econômicos, é crucial equilibrar essa segurança com as emissões de CO₂ no setor elétrico brasileiro. Este trabalho propõe estimar as emissões horárias de CO₂ equivalente (CO₂-e) das termoeletricas brasileiras usando redes neurais para apoiar o planejamento energético e ambiental do Sistema Interligado Nacional. Enquanto a literatura baseia a modelagem dessas emissões em funções específicas para cada usina, as emissões no Brasil são inventariadas pela Eletrobras e pelo Instituto de Energia e Meio Ambiente em uma base anual. Para contornar isso, este estudo discretiza as emissões anuais de cada usina em estimativas horárias, utilizando regressão não linear em função de dados disponibilizados pelo Operador Nacional do Sistema Elétrico. Com isso, é possível generalizar as estimativas de emissões horárias das termoeletricas brasileiras. Este trabalho inclui análises para 39 usinas termelétricas com diferentes capacidades de geração, ciclos de operação e combustíveis, fornecendo *insights* para o planejamento energético, elétrico e ambiental do país.

Palavras-Chave: Emissões de CO₂; Redes Neurais Artificiais; Termelétricas; Calibração; Regularização L2.

Abstract

Aurelio, Giovanni, **CO₂ Emissions Forecasting for National Thermoelectric Power Plants using Artificial Neural Networks**. Final year thesis (Bachelor degree in Electrical Engineering). Exact and Technology Sciences Center, Federal University of São Carlos. 53 p. São Carlos, 2026.

Although most of Brazil's electric energy comes from hydroelectric plants, thermal power plants are crucial for national energy security. However, with climate change caused by CO₂ emissions from various economic sectors, it is crucial to balance this security with CO₂ emissions in the Brazilian electricity sector. This work proposes estimating hourly CO₂ equivalent (CO₂-e) emissions from Brazilian thermal power plants using neural networks to support energy and environmental planning of the National Interconnected System. While the literature bases the modeling of these emissions on specific functions for each plant, emissions in Brazil are inventoried by Eletrobras and the Instituto de Energia e Meio Ambiente on an annual basis. To overcome this, this work discretizes the annual emissions of each plant into hourly estimates using nonlinear regression based on data provided by the Operador Nacional do Sistema Elétrico. This enables generalizing the estimates of hourly emissions from Brazilian thermal power plants. This work includes analyses for 39 thermal power plants with different generation capacities, operation cycles, and fuels, providing insights for energy, electric, and environmental planning in the country.

Keywords: CO₂ Emissions; Artificial Neural Networks; Thermal Power Plants; Calibration; L2 Regularization.

Lista de Figuras

Figura 1 – Quantidade de Usinas por Erro <i>Mean Absolute Error</i> (MAE)	39
Figura 2 – Distribuição das Usinas por Erro MAE	39
Figura 3 – Comparação de Desempenho Favorável e Não Favorável	40
Figura 4 – Quantidade de Usinas por Razão de Instabilidade	41
Figura 5 – Relação entre MAE e Instabilidade	41
Figura 6 – Relação entre MAE e <i>Mean Squared Error</i> (MSE)	42

Lista de Tabelas

Tabela 1 – Arquitetura da Rede Neural MLP	26
Tabela 2 – Tratamento das Variáveis Estáticas	34
Tabela 3 – Tratamento das Variáveis Dinâmicas	34
Tabela 4 – Divisão Temporal dos Dados	36
Tabela 5 – Hiperparâmetros de Treinamento	36
Tabela 6 – Dados para Minimização Padrão	37
Tabela 7 – Dados para Minimização com Regularização L2	38
Tabela 8 – Resumo Estatístico - Sem Regularização	44
Tabela 9 – Resumo Estatístico - Com Regularização L2	45

Lista de Siglas e Abreviaturas

CO₂	Dióxido de Carbono
CO₂e	Dióxido de Carbono Equivalente
tCO₂e	Toneladas de Dióxido de Carbono Equivalente
ONS	Operador Nacional do Sistema Elétrico
IEMA	Instituto de Energia e Meio Ambiente
SIN	Sistema Interligado Nacional
CEG	Cadastro Específico de Geração
AMPL	<i>A Mathematical Programming Language</i>
IPOPT	<i>Interior Point Optimizer</i>
RNL	Regressão Não Linear
MLP	<i>Multilayer Perceptron</i>
GRU	<i>Gated Recurrent Units</i>
LSTM	<i>Long Short-Term Memory</i>
ReLU	<i>Rectified Linear Unit</i>
MSE	<i>Mean Squared Error</i>
MAE	<i>Mean Absolute Error</i>
RMSE	<i>Root Mean Squared Error</i>
SBCE	Sistema Brasileiro de Comércio de Emissões de Gases de Efeito Estufa
CEMS	<i>Continuous Emissions Monitoring System</i>
AR5	<i>Fifth Assessment Report</i>
IPCC	<i>Intergovernmental Panel on Climate Change</i>
MAPE	<i>Mean Absolute Percentage Error</i>

Sumário

1	INTRODUÇÃO	13
2	REVISÃO DE LITERATURA	15
2.1	Métricas de Emissões e Dióxido de Carbono Equivalente (CO ₂ e)	15
2.2	Funções de Emissão Horária	15
2.3	Regressão Não Linear	17
2.4	Geração de Dados Sintéticos	18
2.5	Métricas de Avaliação	19
2.5.1	Erro Absoluto Médio (MAE)	19
2.5.2	Erro Quadrático Médio (MSE)	19
2.5.3	Raiz do Erro Quadrático Médio (<i>Root Mean Squared Error</i> (RMSE))	19
2.5.4	Erro Percentual Absoluto Médio (<i>Mean Absolute Percentage Error</i> (MAPE))	19
2.5.5	Razão de Estabilidade	20
3	METODOLOGIA	21
3.1	Visão Geral	21
3.2	Fontes de Dados e Descrição das Variáveis	21
3.2.1	Operador Nacional do Sistema Elétrico (Operador Nacional do Sistema Elétrico (ONS))	21
3.2.2	Instituto de Energia e Meio Ambiente (Instituto de Energia e Meio Ambiente (IEMA))	22
3.3	Tratamento das Sazonalidades Temporais	22
3.4	Modelagem das Transições Operacionais	22
3.4.1	Definição de Categorias	23
3.4.2	Identificação de Transições	23
3.4.3	Duração e Fase da Transição	23
3.5	Formulação do Problema de Calibração	23
3.5.1	Calibração Padrão	24
3.5.2	Regularização L2 (Ridge)	25
3.6	Emissões Sintéticas como Alvos para Aprendizado	25
3.7	Arquitetura da Rede Neural	25
3.7.1	Estrutura das Camadas	26
3.7.2	Estratégias de Regularização Adicionais	26

3.8	Variáveis de Entrada e Pré-processamento Conceitual	27
3.8.1	Variáveis Estáticas	27
3.8.2	Variáveis Dinâmicas	27
3.8.3	Tratamento das Variáveis	27
3.9	Métricas de Avaliação	28
3.9.1	Erro Absoluto Médio (MAE)	28
3.9.2	Erro Quadrático Médio (MSE)	28
3.9.3	Raiz do Erro Quadrático Médio (RMSE)	28
3.9.4	Razão de Estabilidade	28
4	DESENVOLVIMENTO	30
4.1	Organização Geral da Implementação	30
4.2	Implementação do Pré-Processamento	30
4.2.1	Filtragem das Usinas e Organização Temporal	31
4.2.2	Classificação das Categorias de Geração	31
4.2.3	Identificação de Transições	31
4.2.4	Cálculo da Duração e Fase da Transição	32
4.3	Implementação da Calibração no <i>A Mathematical Program-</i> <i>ming Language</i> (AMPL)	32
4.3.1	Estrutura do Modelo de Otimização	32
4.3.2	Integração Python-AMPL	33
4.3.3	Ajuste do Parâmetro de Regularização λ	33
4.3.4	Geração das Emissões Sintéticas Horárias	33
4.4	Preparação das Features para a Rede Neural	34
4.5	Implementação da Rede Neural	34
4.5.1	Construção da Arquitetura <i>Multilayer Perceptron</i> (MLP) . .	35
4.5.2	Ponderação Diferenciada para Transições	35
4.5.3	Early Stopping e Gradient Clipping	36
4.6	Divisão dos Dados e Configuração do Treinamento	36
5	RESULTADOS	37
5.1	Visão Geral dos Experimentos	37
5.2	Análise da Calibração (AMPL)	37
5.3	Desempenho da Rede Neural	38
5.3.1	Distribuição Geral dos Erros	38
5.3.2	Melhores e Piores Desempenhos	40
5.3.3	Análise de Estabilidade	41
5.3.4	Relação entre Métricas	41
5.4	Síntese e Discussão	42

6	CONCLUSÕES	46
	REFERÊNCIAS BIBLIOGRÁFICAS	48
A	APÊNDICE A - PSEUDOCÓDIGOS	50
A.1	Classificação das Categorias de Geração	50
A.2	Identificação de Transições	51
A.3	Modelo de Otimização AMPL	51
A.4	Treinamento da Rede Neural	52

1 Introdução

O setor elétrico brasileiro possui uma matriz predominantemente renovável, com destaque para as usinas hidrelétricas, que historicamente respondem pela maior parte da geração de energia elétrica no país. No entanto, períodos de estiagem prolongada, aliados ao crescimento da demanda e à necessidade de segurança energética, exigem o acionamento frequente de usinas termelétricas. Embora essas usinas sejam fundamentais para garantir o suprimento contínuo de energia, sua operação está associada à emissão de gases de efeito estufa, especialmente o Dióxido de Carbono (CO_2). As mudanças climáticas, impulsionadas pelas emissões de diversos setores econômicos, têm imposto desafios crescentes aos planejadores energéticos. No Brasil, o Sistema Interligado Nacional (SIN) requer ferramentas que permitam equilibrar a segurança do suprimento elétrico com as metas de descarbonização assumidas pelo país em acordos internacionais. Nesse contexto, a estimação precisa das emissões de CO_2 das termelétricas em escala horária torna-se um insumo relevante para o despacho econômico-ambiental e para o planejamento da operação.

A literatura internacional apresenta modelos consolidados para a estimação de emissões horárias de usinas termelétricas, geralmente baseados em funções quadráticas ou exponenciais calibradas a partir de medições contínuas ou de dados de projeto de cada usina. No entanto, o cenário brasileiro apresenta uma particularidade: os dados de emissões de CO_2 das termelétricas são inventariados anualmente — e não horariamente — por instituições como o IEMA e, anteriormente, pela Eletrobras. Essa disponibilidade exclusivamente anual de dados impõe um problema de natureza inversa: é necessário estimar o comportamento horário das emissões a partir de agregados anuais. Além disso, as termelétricas brasileiras operam com diferentes tipos de combustível (gás natural, óleo diesel, carvão mineral, biomassa), diferentes ciclos de operação (ciclo simples, ciclo combinado) e operam em patamares discretos de carga, com transições entre níveis de geração que afetam a eficiência e, conseqüentemente, as emissões. A literatura nacional ainda carece de metodologias sistemáticas para a discretização temporal das emissões anuais em estimativas horárias que considerem essas particularidades operacionais e que sejam generalizáveis para diferentes usinas.

Diante desse cenário, este trabalho propõe uma metodologia para estimar as emissões horárias de CO_2 das usinas termelétricas brasileiras, combinando técnicas de otimização não-linear e redes neurais artificiais. A metodologia estrutura-se em duas etapas principais. Na primeira etapa, calibram-se os coeficientes de uma equação paramétrica de emissão (composta por termos quadrático e exponencial) por meio de um problema de minimização resolvido em AMPL com o solver *Interior Point Optimizer* (IPOPT), utilizando como referência os totais anuais do IEMA. Dois cenários são comparados:

calibração padrão e calibração com regularização L2. Na segunda etapa, as emissões sintéticas horárias geradas tornam-se alvos para o treinamento de uma rede neural MLP, que aprende diretamente a relação entre variáveis operacionais (geração, categoria de operação, fase de transição), características estáticas da usina (combustível, potência instalada, eficiência) e as emissões horárias. Mais especificamente, o trabalho desenvolve um algoritmo de classificação de categorias de geração e identificação de transições operacionais com base em limiares adaptativos, calibra os coeficientes da equação de emissão para 39 usinas termelétricas brasileiras no período de 2020 a 2024, treina e valida uma rede neural MLP para estimar emissões horárias, e compara o desempenho dos cenários de calibração (padrão vs. L2) em termos de precisão e estabilidade.

Como contribuições principais, este trabalho oferece uma metodologia sistemática para discretização de emissões anuais em estimativas horárias aplicável a termelétricas com diferentes combustíveis e ciclos de operação; uma base de dados integrada combinando informações da ONS e do IEMA para 39 usinas em um período de 5 anos, com enriquecimento de *features* temporais (categorias, transições, fases); uma comparação quantitativa entre calibração padrão e com regularização L2, fornecendo subsídios para a escolha da estratégia mais adequada em problemas de calibração inversa no setor elétrico; e um modelo de rede neural treinado para estimação horária de emissões, com análise de desempenho por categoria operacional e tipo de combustível. Essas contribuições podem apoiar o planejamento energético e ambiental do SIN, fornecendo insumos horários para modelos de despacho econômico-ambiental e para a avaliação de políticas de descarbonização.

2 Revisão de Literatura

2.1 Métricas de Emissões e CO₂e

A quantificação de emissões de gases de efeito estufa no setor energético brasileiro segue as diretrizes do *Intergovernmental Panel on Climate Change* (IPCC). Para todo gás $g \in \{\text{CO}_2, \text{CH}_4, \text{N}_2\text{O}\}$ e combustível f , as emissões são descritas em função da energia consumida e de fatores de emissão específicos: $E_g = \sum_f \text{AD}_f \cdot \text{EF}_{f,g}$, onde AD_f são os dados de atividade (*Activity Data*), correspondentes à energia consumida (em TJ), e $\text{EF}_{f,g}$ é o fator de emissão (*Emission Factor*) do gás g para o combustível f (em kg/TJ) (IPCC, 2006).

Após a quantificação das emissões individuais de cada gás, os inventários convertem o valor na unidade equivalente de dióxido de carbono (CO₂e), utilizando os potenciais de aquecimento global (*Global Warming Potential*) do *Fifth Assessment Report* (AR5):

$$\text{CO}_2e = \text{CO}_2 + 28 \cdot \text{CH}_4 + 265 \cdot \text{N}_2\text{O} \quad (2.1)$$

(IPCC, 2014). O IEMA adota esta conversão em seus inventários anuais de emissões atmosféricas de usinas termelétricas, publicados a partir do ano-base 2020 (IEMA, 2022; IEMA, 2023; IEMA, 2024). Adicionalmente, o IEMA divulga a taxa de emissão de cada usina em Toneladas de Dióxido de Carbono Equivalente (tCO₂e)/GWh, definida como a razão entre a emissão anual de CO₂e e a energia elétrica gerada no ano, permitindo acompanhar o desempenho ambiental das plantas.

2.2 Funções de Emissão Horária

A estimativa de emissões de uma usina termelétrica em função da sua geração elétrica é um problema recorrente no despacho econômico-ambiental de sistemas de potência. A relação física subjacente decorre da cadeia de conversão energética: a queima do combustível libera energia térmica, que é convertida em trabalho mecânico e, posteriormente, em energia elétrica. Como o fator de emissão do combustível (kg CO₂/GJ) é aproximadamente constante para um dado tipo de combustível, a emissão apresenta a mesma forma funcional que o consumo de combustível (IPCC, 2006). Essa propriedade permite modelar diretamente a emissão como função da potência gerada, sem a necessidade de calcular o consumo intermediário de combustível.

A curva de entrada e saída (*input-output curve*) de uma unidade térmica, que relaciona o aporte térmico H (em GJ/h) à potência elétrica gerada P (em MW), é classicamente

representada por um polinômio de segundo grau (WOOD; WOLLENBERG; SHEBLÉ, 2013):

$$H(P) = a + bP + cP^2 \quad (2.2)$$

onde a representa o aporte térmico a vazio (*no-load heat*), b o *heat rate* incremental e c a curvatura associada à perda de eficiência em cargas elevadas. Multiplicando-se cada coeficiente pelo fator de emissão ρ (kg CO₂e/GJ), obtém-se diretamente a emissão horária como função da potência gerada:

$$E(P) = a + bP + cP^2 \quad [\text{tCO}_2\text{e/h}] \quad (2.3)$$

onde a , b e c são coeficientes de emissão intrínsecos a cada usina, determinados experimentalmente ou por ajuste a dados operacionais (GENT; LAMONT, 1971; WOOD; WOLLENBERG; SHEBLÉ, 2013).

Essa formulação quadrática foi proposta por Gent e Lamont (GENT; LAMONT, 1971) no contexto do despacho de mínima emissão de NO_x e é amplamente adotada como modelo padrão para representar emissões em regime permanente (KOTHARI; DHILLON, 2011). No mesmo trabalho, os autores propuseram uma extensão com termo exponencial para capturar o aumento abrupto de emissões em altas cargas:

$$E(P) = a + bP + cP^2 + d \exp(eP) \quad (2.4)$$

Essa formulação foi posteriormente consolidada na revisão de Talaq, El-Hawary e El-Hawary (TALAQ; EL-HAWARY; EL-HAWARY, 1994), que compilou os algoritmos de despacho econômico-ambiental desenvolvidos desde 1970. Para CO₂, cuja emissão depende essencialmente da quantidade de combustível queimado e não da temperatura de combustão, a forma quadrática é geralmente suficiente. No entanto, a formulação com termo exponencial é adotada neste trabalho por sua maior flexibilidade para capturar não-linearidades observadas nos dados de diferentes usinas.

Além da forma polinomial, outras representações funcionais têm sido empregadas para capturar a degradação de eficiência em carga parcial. A forma logarítmica utiliza o fato de que o *heat rate* específico cresce de maneira aproximadamente logarítmica conforme a carga se afasta do ponto de projeto (U.S. Energy Information Administration, 2015). A forma exponencial pura, $E = a \exp(bP)$, penaliza de maneira mais acentuada operações em carga parcial reduzida, sendo empregada em estudos de flexibilidade operacional de usinas a carvão (HENDERSON, 2014).

Cabe ressaltar que todas essas formulações pressupõem operação em regime permanente. Na prática, usinas termelétricas estão sujeitas a mudanças operacionais, como partidas (*start-up*), paradas (*shut-down*) e rampas de carga, que introduzem emissões adicionais não capturadas pelos modelos de regime estacionário (KUMAR et al., 2012).

Dentre esses eventos, a partida é particularmente relevante sob a ótica ambiental: ao ligar uma caldeira, é necessário reaquecer a massa metálica do sistema, purgar gases residuais e estabilizar a combustão, consumindo combustível adicional enquanto a unidade ainda não atingiu a potência mínima para conexão ao sistema (KUMAR et al., 2012).

2.3 Regressão Não Linear

As formas funcionais apresentadas na seção anterior descrevem a emissão horária de uma termelétrica em função da potência gerada e de variáveis operacionais. Contudo, os coeficientes dessas funções são específicos de cada usina e precisam ser determinados a partir de dados operacionais. Quando a forma funcional contém termos exponenciais, logarítmicos ou racionais, os coeficientes aparecem de maneira não linear no modelo, e sua estimação requer técnicas de Regressão Não Linear (RNL) (SEBER; WILD, 1989).

Em termos formais, dado um modelo paramétrico $f(\mathbf{x}; \boldsymbol{\theta})$, onde $\boldsymbol{\theta} \in \mathbb{R}^q$ é o vetor de parâmetros a ser estimado, o modelo é classificado como não linear nos parâmetros quando ao menos uma derivada parcial $\partial f / \partial \theta_j$ depende do próprio vetor $\boldsymbol{\theta}$. Nessa situação, não existe solução analítica fechada para a estimação dos coeficientes, sendo necessário recorrer a algoritmos iterativos de otimização numérica. Modelos lineares nos parâmetros, como polinômios ($E = a + bP + cP^2$), possuem solução analítica por Mínimos Quadrados Ordinários, mas por conveniência podem ser ajustados pelo mesmo algoritmo de otimização utilizado para os demais modelos (SEBER; WILD, 1989).

A estimação dos parâmetros consiste em encontrar o vetor $\hat{\boldsymbol{\theta}}$ que minimize uma função objetivo $\mathcal{J}$, a qual quantifica a discrepância entre os valores observados e os preditos pelo modelo:

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta}} \mathcal{J}(\mathbf{y}, f(\mathbf{X}; \boldsymbol{\theta})) \quad (2.5)$$

A escolha de $\mathcal{J}$ depende das características do problema. A soma dos quadrados dos resíduos (MSE) é a formulação clássica, mas alternativas como o MAE e o MAPE podem ser preferíveis em determinados cenários. O MSE eleva os resíduos ao quadrado, amplificando o peso de valores discrepantes e puxando a solução para acomodá-los; o MAE trata os desvios linearmente, resultando em ajuste mais robusto a *outliers*. O MAPE, por sua vez, normaliza cada resíduo pela magnitude da observação, sendo útil quando se deseja avaliar o erro em termos relativos (MYTTENAERE et al., 2016).

No contexto de curvas de emissão de termelétricas, os coeficientes do modelo possuem significado físico e devem ser não negativos ($\theta \geq 0$), uma vez que representam taxas de emissão ou de consumo que são positivas por natureza (WOOD; WOLLENBERG; SHEBLÉ, 2013).

Na prática, a convergência dos algoritmos iterativos utilizados em RNL depende da escolha de valores iniciais e limites de busca adequados. A adoção de estimativas inici-

ais baseadas em conhecimento físico do problema assegura que a solução obtida possua significado físico e contribui para a aceleração da convergência (SEBER; WILD, 1989).

2.4 Geração de Dados Sintéticos

Conforme apresentado na Introdução, os inventários do IEMA fornecem emissões em resolução anual, enquanto os registros do ONS estão disponíveis em base horária. Essa incompatibilidade temporal impede a aplicação direta de técnicas de regressão para modelar emissões horárias. A alternativa adotada neste trabalho consiste em gerar uma base de dados sintéticos horários de emissão, utilizando modelos paramétricos calibrados com os totais anuais disponíveis.

A geração de dados sintéticos busca criar dados que minimamente descrevam efeitos físicos e reais quando aqueles não estão disponíveis, seja por falta de medição ou por questões de confidencialidade. A ideia não é reproduzir cada observação individualmente, mas gerar amostras que preservem as relações estatísticas entre a variável resposta e os preditores presentes nos dados originais (NOWOK; RAAB; DIBBEN, 2016).

Na prática, isso requer a formulação de um modelo estatístico ou físico-matemático que represente o fenômeno de interesse. A partir desse modelo e de uma base de dados real, geram-se novas observações de modo que a base artificial resultante preserve as correlações e a variabilidade dos dados originais (NOWOK; RAAB; DIBBEN, 2016).

Assim, a criação de dados sintéticos, quando bem sucedida, permite realizar testes e experimentos sobre uma base de dados que, se tratada apenas com os valores originais, seria insuficiente para estudo. Porém, como essa geração artificial depende diretamente do modelo utilizado e dos dados originais, quanto melhor o modelo descrever a realidade e quanto menor o ruído nos dados de entrada, maior será a confiabilidade dos dados sintéticos. Ainda assim, os dados sintéticos gerados podem reproduzir o formato geral das distribuições, distorcer dependências ou não preservar valores extremos e eventos esparsos (NOWOK; RAAB; DIBBEN, 2016; STENGER et al., 2024).

A geração de bases sintéticas para variáveis dependentes do tempo ou altamente correlacionadas apresenta desafios adicionais. Uma série temporal sintética pode, por exemplo, reproduzir a distribuição marginal de cada variável, mas falhar em replicar padrões de autocorrelação ou relações de defasagem (STENGER et al., 2024).

Em síntese, dados sintéticos constituem um recurso valioso para experimentação e validação quando dados reais são insuficientes, desde que interpretados com cautela — embora sejam capazes de aproximar a estrutura estatística do conjunto original, podem introduzir viés ou enfraquecer relações dinâmicas entre variáveis. A documentação completa do método de geração, das escolhas de parâmetros e de suas limitações é, portanto, essencial para o uso confiável desses dados (NOWOK; RAAB; DIBBEN, 2016; STENGER et al., 2024).

2.5 Métricas de Avaliação

Para quantificar a qualidade do ajuste e a capacidade preditiva dos modelos, são empregadas métricas estatísticas complementares. Essas métricas são utilizadas tanto na etapa de ajuste dos modelos de RNL (como função objetivo a ser minimizada) quanto na avaliação da rede neural. Em todas as definições a seguir, y_i denota o valor observado, $\hat{y}_i$ o valor predito pelo modelo, $\bar{y}$ a média das observações e N o número total de amostras.

2.5.1 Erro Absoluto Médio (MAE)

O MAE mensura a média aritmética dos desvios absolutos entre valores preditos e observados. Por tratar os desvios de forma linear, é mais robusto a *outliers* do que o MSE (WILLMOTT; MATSUURA, 2005):

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (2.6)$$

2.5.2 Erro Quadrático Médio (MSE)

O MSE calcula a média dos quadrados dos desvios. Por elevar os erros ao quadrado, penaliza mais severamente erros de grande magnitude (BICKEL; DOKSUM, 2015):

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2.7)$$

2.5.3 Raiz do Erro Quadrático Médio (RMSE)

O RMSE é obtido pela raiz quadrada do MSE, apresentando o erro na mesma unidade dimensional da variável resposta, o que facilita a interpretação física do desvio (CHAI; DRAXLER, 2014):

$$\text{RMSE} = \sqrt{\text{MSE}} \quad (2.8)$$

2.5.4 Erro Percentual Absoluto Médio (MAPE)

O MAPE expressa o desvio em termos relativos (porcentagem), sendo útil para comparar o desempenho do modelo em diferentes escalas de magnitude (MYTTENAERE et al., 2016):

$$\text{MAPE} = \frac{100}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2.9)$$

2.5.5 Razão de Estabilidade

A razão $R = \text{MSE}/\text{MAE}^2$ é empregada como indicador da estabilidade do modelo. Valores baixos de R indicam que os erros são consistentes, enquanto valores altos sugerem que erros grandes ocorrem com frequência não desprezível:

$$R = \frac{\text{MSE}}{\text{MAE}^2} \quad (2.10)$$

A interpretação adotada neste trabalho é:

- $R < 3$: modelo estável, erros concentrados em torno da média;
- $3 \leq R \leq 5$: instabilidade moderada, presença de alguns *outliers*;
- $R > 5$: presença significativa de *outliers*, modelo pouco confiável.

3 Metodologia

3.1 Visão Geral

A estimação horária de emissões de CO₂ em usinas termelétricas configura-se como um problema inverso: dispõe-se de medições anuais agregadas, fornecidas pelos inventários do IEMA, mas necessita-se do comportamento horário para aplicações em planejamento energético e despacho econômico-ambiental. Além disso, a relação entre geração horária e emissão é intrinsecamente não-linear (GENT; LAMONT, 1971; TALAQ; EL-HAWARY; EL-HAWARY, 1994).

Para enfrentar esses desafios, a metodologia proposta estrutura-se em duas etapas complementares. Na primeira etapa, resolve-se um problema de otimização não-linear para calibrar os coeficientes de uma equação paramétrica de emissão horária, utilizando como referência os totais anuais disponibilizados pelo IEMA. Para mitigar o mal condicionamento desse problema inverso, aplica-se regularização L2 (Ridge), sendo comparados dois cenários: calibração padrão e calibração com regularização.

Na segunda etapa, as emissões sintéticas horárias geradas pela equação calibrada tornam-se o alvo (*target*) para o treinamento de uma rede neural MLP. A rede aprende diretamente a relação entre as variáveis operacionais (geração, categoria de operação, fase de transição), as características estáticas da usina (combustível, potência instalada, eficiência) e a emissão horária, sem incorporar explicitamente a equação física na função de perda.

Essa abordagem em cascata permite: (i) garantir consistência com os totais anuais do IEMA; (ii) capturar não-linearidades que a equação paramétrica pode não expressar plenamente; e (iii) avaliar, por meio da comparação entre os cenários padrão e L2, qual estratégia de calibração produz alvos sintéticos mais coerentes para o aprendizado supervisionado.

3.2 Fontes de Dados e Descrição das Variáveis

Foram empregadas duas fontes principais de dados, abrangendo o período de 2020 a 2024.

3.2.1 Operador Nacional do Sistema Elétrico (ONS)

Por meio da iniciativa Dados Abertos, obtém-se a geração horária de todas as usinas do SIN. Os registros incluem: identificação da usina, data, hora e geração horária em MW. O conjunto é filtrado para reter apenas usinas termelétricas (ONS, 2021).

3.2.2 Instituto de Energia e Meio Ambiente (IEMA)

Os inventários anuais do IEMA fornecem (IEMA, 2022; IEMA, 2023; IEMA, 2024):

- Emissões totais anuais de tCO₂e por usina;
- Características cadastrais fixas: potência instalada (MW), fator de capacidade (%), eficiência energética (%), tipo de combustível e ciclo de operação (ciclo combinado, ciclo simples, cogeração).

Usinas de cogeração são excluídas da análise por não apresentarem, nos inventários do IEMA, informações completas de potência instalada e eficiência — características indispensáveis à modelagem. Após a integração das fontes e a remoção de registros faltantes, restam 39 usinas termelétricas com dados completos para o período 2020-2024. As emissões anuais são mantidas em tCO₂e, e a geração horária em MW.

3.3 Tratamento das Sazonalidades Temporais

As variáveis temporais *Índice* (posição da hora dentro do ano) e *Ano* não podem ser tratadas como grandezas ordinais lineares, pois a relação entre instantes próximos ao final e ao início de um ano ou período não é capturada por uma codificação escalar convencional.

Para preservar a periodicidade natural do calendário, adota-se uma codificação polar (seno/cosseno). Dado um índice $i \in [1, H]$, onde $H \in \{8760, 8784\}$ representa as horas do respectivo ano (considerando anos bissextos), definem-se as seguintes transformações:

$$\text{Seno_Índice}(i) = \sin\left(\frac{2\pi i}{H}\right), \quad \text{Cosseno_Índice}(i) = \cos\left(\frac{2\pi i}{H}\right) \quad (3.1)$$

Analogamente, para o ano $a \in [2020, 2024]$, define-se:

$$\text{Seno_Ano}(a) = \sin\left(\frac{2\pi(a - 2020)}{4}\right), \quad \text{Cosseno_Ano}(a) = \cos\left(\frac{2\pi(a - 2020)}{4}\right) \quad (3.2)$$

Essa representação mapeia valores temporais para pontos sobre o círculo unitário, de modo que instantes próximos (ex: hora 8760 e hora 1) tornam-se vizinhos no espaço polar, refletindo sua continuidade temporal.

3.4 Modelagem das Transições Operacionais

Termelétricas operam tipicamente em patamares discretos de carga, não em regime continuamente variável. Para capturar esse comportamento, define-se um sistema de categorias de geração com base na proximidade relativa entre valores de potência.

3.4.1 Definição de Categorias

Dada a série de geração horária $G = [g_1, g_2, \dots, g_T]$ em MW, valores inferiores a 20 MW são classificados na categoria 0 (carga muito baixa ou desligamento). Para os demais valores, dois pontos pertencem à mesma categoria se sua diferença relativa for inferior ou igual a um limiar $\theta = 15\%$ do maior valor do grupo.

Formalmente, g_i e g_j pertencem à mesma categoria se:

$$\frac{|g_i - g_j|}{\max(g_i, g_j)} \leq \theta \quad (3.3)$$

O limiar de 15% foi definido com base na análise exploratória da distribuição dos incrementos de carga nos dados do ONS, representando o valor típico que separa regimes operacionais distintos sem fragmentar artificialmente a operação.

3.4.2 Identificação de Transições

Seja c_t a categoria no instante t . Define-se a moda m_t das categorias em uma janela de três horas anteriores e três horas posteriores, excluindo o próprio instante:

$$m_t = \text{moda}\{c_{t-3}, c_{t-2}, c_{t-1}, c_{t+1}, c_{t+2}, c_{t+3}\} \quad (3.4)$$

O instante t é classificado como **transição** se $c_t \neq m_t$. Este critério captura períodos de rampa de carga (partidas, paradas e variações controladas), nos quais o fator de emissão horária pode diferir substancialmente do regime estabilizado (KUMAR et al., 2012).

3.4.3 Duração e Fase da Transição

Para cada evento de transição contínuo (sequência de horas consecutivas classificadas como transição), definem-se:

- **Duração d** : número de horas consecutivas do evento;
- **Fase f** : posição relativa dentro do evento, classificada como 1 (início), 2 (meio) ou 3 (fim). Transições com duração $d = 1$ recebem $f = 1$ (início e fim coincidentes).

Essas variáveis permitem que o modelo compreenda a transição como um processo contínuo, com dinâmica de emissão potencialmente distinta ao longo de suas fases.

3.5 Formulação do Problema de Calibração

A relação entre geração horária e emissão horária é modelada por uma equação com termo quadrático e termo exponencial, conforme proposta na literatura (GENT; LAMONT, 1971; TALAQ; EL-HAWARY; EL-HAWARY, 1994):

$$E_k^{\text{horária}}(P_{G_i}) = \alpha_k P_{G_i}^2 + \beta_k P_{G_i} + \gamma_k + \omega_k e^{\mu_k P_{G_i}} \quad (3.5)$$

onde:

- P_{G_i} representa a geração em MW, dividida por 100 para normalização dos dados, garantindo estabilidade numérica no termo exponencial;
- $\alpha_k, \beta_k, \gamma_k, \omega_k, \mu_k$ são coeficientes a serem calibrados por usina;
- O subscrito k indica a usina.

3.5.1 Calibração Padrão

Os coeficientes são obtidos resolvendo o seguinte problema de minimização, que busca minimizar o erro quadrático médio entre a emissão anual estimada (somatório das emissões horárias) e a emissão anual real fornecida pelo IEMA:

$$\min_{\alpha, \beta, \gamma, \omega, \mu} \frac{1}{N} \sum_{j=1}^N \left(\sum_{i=1}^H E_{\text{usina}}^i(P_{G_i}) - E_{\text{usina}}^j \right)^2 \quad (3.6)$$

sujeito às restrições físicas:

$$\alpha \geq 0, \quad \mu \leq \mu_{\max} \quad (3.7)$$

onde:

- N é o número de usinas;
- H é o número de horas do respectivo ano ($H = 8760$ para anos não bissextos, $H = 8784$ para anos bissextos);
- E_{usina}^j é a emissão anual real do IEMA para a usina j ;
- $\mu_{\max}$ é um limite superior para evitar *overflow* numérico do termo exponencial (definido empiricamente em 0, 5).

Apenas o coeficiente α foi explicitamente restringido à não-negatividade, por representar o termo quadrático associado ao crescimento da emissão em cargas elevadas. Os coeficientes γ e ω foram mantidos livres para permitir maior flexibilidade durante a calibração do problema inverso (WOOD; WOLLENBERG; SHEBLÉ, 2013).

3.5.2 Regularização L2 (Ridge)

O problema de calibração inversa é intrinsecamente mal condicionado, podendo produzir coeficientes excessivamente elevados que se cancelam mutuamente (*overfitting* na calibração). Para mitigar esse efeito, introduz-se um termo de regularização L2 (Tikhonov) à função objetivo (TIKHONOV; ARSENIN, 1977):

$$\min \frac{1}{N} \sum_{j=1}^N \left(\sum_{i=1}^H E_{\text{usina}}^i(P_{G_i}) - E_{\text{usina}}^j \right)^2 + \lambda (\alpha^2 + \beta^2 + \gamma^2 + \omega^2 + \mu^2) \quad (3.8)$$

sujeito às mesmas restrições da calibração padrão (Equação 3.7).

O parâmetro $\lambda \geq 0$ controla a intensidade da regularização: $\lambda = 0$ recupera o problema padrão, enquanto valores positivos penalizam coeficientes de grande magnitude, promovendo soluções mais estáveis e generalizáveis. O valor de λ deve ser selecionado de forma a equilibrar a redução do erro de calibração e a estabilidade dos coeficientes.

3.6 Emissões Sintéticas como Alvos para Aprendizado

Uma vez calibrados os coeficientes (para os cenários padrão e com regularização L2), aplica-se a Equação 3.5 sobre a série horária de geração para produzir as **emissões sintéticas horárias** $\hat{E}_t$. Essas emissões sintéticas tornam-se a variável alvo para o treinamento supervisionado da rede neural.

É importante observar que a rede neural, ao ser treinada com esses alvos sintéticos, herda os erros de modelagem da equação paramétrica e da calibração. Conforme discutido na literatura (NOWOK; RAAB; DIBBEN, 2016; STENGER et al., 2024), os dados sintéticos gerados por modelos paramétricos refletem integralmente as premissas e limitações do modelo utilizado. Portanto, a comparação entre os cenários padrão e L2 não avalia apenas a qualidade da rede, mas também qual estratégia de calibração produz alvos mais consistentes para o aprendizado supervisionado.

A fidelidade da base sintética depende diretamente da qualidade do ajuste e da capacidade do modelo paramétrico em representar o comportamento real de emissão da usina.

3.7 Arquitetura da Rede Neural

Optou-se por uma arquitetura do tipo MLP em detrimento de redes recorrentes (*Long Short-Term Memory* (LSTM), *Gated Recurrent Units* (GRU)) porque a emissão horária, no modelo proposto, depende essencialmente da geração no mesmo instante t , e não de uma sequência temporal longa. A MLP é suficiente, mais simples e menos suscetível a

overfitting com o volume de dados disponível (GOODFELLOW; BENGIO; COURVILLE, 2016).

3.7.1 Estrutura das Camadas

A Tabela 1 apresenta a arquitetura adotada.

Camada	Neurônios	Ativação	Regularização
Entrada	d_{in}	—	—
Ocultas 1	128	<i>Rectified Linear Unit</i> (ReLU)	Dropout (0,3)
Ocultas 2	64	ReLU	Dropout (0,3)
Ocultas 3	32	ReLU	Dropout (0,3)
Saída	1	ReLU	—

Tabela 1 – Arquitetura da Rede Neural MLP

A arquitetura em funil ($128 \rightarrow 64 \rightarrow 32$) reduz progressivamente a capacidade representacional, atuando como uma forma implícita de regularização e prevenindo *overfitting*. A função de ativação ReLU é escolhida por sua simplicidade computacional e por mitigar o problema do gradiente evanescente em comparação com funções sigmoidais (GOODFELLOW; BENGIO; COURVILLE, 2016). O *dropout* com taxa de 0,3 desativa aleatoriamente 30% dos neurônios a cada iteração de treinamento, forçando a rede a aprender representações redundantes e robustas (SRIVASTAVA et al., 2014).

3.7.2 Estratégias de Regularização Adicionais

Além do *dropout*, empregam-se as seguintes estratégias de regularização:

- **Early stopping:** o treinamento é interrompido quando a perda no conjunto de validação não apresenta melhora por um número pré-definido de épocas (paciência), restaurando os pesos da melhor época. Isso evita *overfitting* ao interromper o treinamento antes que a rede memorize ruídos (GOODFELLOW; BENGIO; COURVILLE, 2016).
- **Gradient clipping:** a norma L2 do vetor de gradientes é limitada a um valor máximo antes da atualização dos pesos. Esta técnica previne a explosão dos gradientes, fenômeno que pode ocorrer quando a função de perda apresenta regiões de alta curvatura ou quando amostras com pesos elevados produzem gradientes desproporcionais (GOODFELLOW; BENGIO; COURVILLE, 2016).

3.8 Variáveis de Entrada e Pré-processamento Contextual

As variáveis de entrada da rede neural são agrupadas em duas categorias: estáticas e dinâmicas.

3.8.1 Variáveis Estáticas

Variáveis estáticas são invariantes no tempo para cada usina:

- Tipo de combustível (categórica, sem ordem intrínseca);
- Ciclo de operação (categórica);
- Potência instalada (MW) — grandeza com significado físico direto;
- Eficiência energética (%) — grandeza com significado físico direto;
- Fator de capacidade (%) — grandeza com significado físico direto.

3.8.2 Variáveis Dinâmicas

Variáveis dinâmicas variam a cada hora:

- Geração horária (MW);
- Categoria de geração (categórica, proveniente da classificação descrita na Seção 4);
- Duração da transição (h);
- Fase da transição (1, 2 ou 3);
- Índice temporal (codificado polarmente conforme Seção 3);
- Ano (codificado polarmente conforme Seção 3).

3.8.3 Tratamento das Variáveis

Variáveis categóricas (combustível, ciclo de operação, categoria de geração) são transformadas por *one-hot encoding*, que as converte em vetores binários sem impor ordenação artificial.

Variáveis contínuas de diferentes ordens de grandeza (geração, duração, fase) requerem padronização para que todas contribuam igualmente durante o treinamento. Adota-se a padronização *z-score*:

$$x_{\text{pad}} = \frac{x - \mu}{\sigma} \quad (3.9)$$

onde μ e σ são a média e o desvio padrão estimados **exclusivamente** nos dados de treinamento, para evitar vazamento de informações do futuro.

3.9 Métricas de Avaliação

Para avaliar a qualidade das estimativas, empregam-se as seguintes métricas (CHAI; DRAXLER, 2014; WILLMOTT; MATSUURA, 2005; MYTTENAERE et al., 2016).

3.9.1 Erro Absoluto Médio (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.10)$$

Interpretável diretamente na unidade original (tCO₂/h).

3.9.2 Erro Quadrático Médio (MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.11)$$

Penaliza mais severamente erros grandes, sendo útil para detectar a presença de *outliers*.

3.9.3 Raiz do Erro Quadrático Médio (RMSE)

$$\text{RMSE} = \sqrt{\text{MSE}} \quad (3.12)$$

Devolve a métrica à unidade original (tCO₂/h), combinando a sensibilidade a *outliers* do MSE com a interpretabilidade do MAE.

3.9.4 Razão de Estabilidade

A razão $R = \text{MSE}/\text{MAE}^2$ é empregada como indicador da estabilidade do modelo. Esta razão está diretamente relacionada à distribuição dos erros e à presença de *outliers*. Para uma distribuição normal de erros, a razão converge para $\pi/2 \approx 1,57$, pois $\text{MSE} = \sigma^2$ e $\text{MAE} = \sigma\sqrt{2/\pi}$, resultando em $\text{MSE}/\text{MAE}^2 = \pi/2$.

Com base nesta propriedade e em considerações práticas, adotam-se os seguintes limites:

- $R < 3$: modelo estável, erros concentrados em torno da média (até aproximadamente o dobro do valor teórico);
- $3 \leq R \leq 5$: instabilidade moderada, presença de alguns *outliers*;
- $R > 5$: presença significativa de *outliers*, modelo pouco confiável.

Estes limiares foram definidos com base na análise exploratória dos dados e na experiência prática do autor, sendo utilizados como referência para comparação entre os cenários avaliados.

4 Desenvolvimento

4.1 Organização Geral da Implementação

Todo o código foi desenvolvido na linguagem Python, versão 3.10.12, utilizando as bibliotecas Pandas e NumPy para manipulação dos dados, AMPL (via biblioteca `amplpy`) para a calibração dos coeficientes, e PyTorch para a construção e treinamento da rede neural. As sementes aleatórias foram fixadas (`random.seed(42)`, `np.random.seed(42)`, `torch.manual_seed(42)`) em todos os experimentos para garantir reprodutibilidade.

O desenvolvimento foi estruturado em três módulos principais:

- **Módulo 1 – Pré-processamento:** filtragem das usinas, organização temporal, classificação de categorias, identificação de transições e cálculo de duração e fase;
- **Módulo 2 – Calibração (AMPL/IPOPT):** modelagem do problema de otimização, integração Python-AMPL, ajuste do parâmetro de regularização e geração das emissões sintéticas;
- **Módulo 3 – Rede Neural (PyTorch):** construção da arquitetura MLP, ponderação das amostras, treinamento com *early stopping* e *gradient clipping*.

Todos os experimentos foram executados em um computador com processador AMD Ryzen 5 5600X (12 núcleos), 16 GB de RAM e GPU NVIDIA RTX 5070 (12 GB), sob sistema operacional Windows 11. O tempo total de processamento foi de aproximadamente:

- Pré-processamento: 45 segundos;
- Calibração no AMPL (39 usinas): 2 horas e 15 minutos (paralelizado em 8 núcleos);
- Treinamento da rede neural: 47 minutos (cenário padrão) e 48 minutos (cenário L2), com 230 e 245 épocas respectivamente, ambos interrompidos por *early stopping*.

4.2 Implementação do Pré-Processamento

O pré-processamento dos dados constitui a primeira etapa computacional do trabalho, sendo responsável por transformar os dados brutos do ONS e do IEMA em um conjunto estruturado, evidenciando os dados temporais.

4.2.1 Filtragem das Usinas e Organização Temporal

O primeiro passo consistiu em integrar as duas fontes de dados e garantir a consistência do conjunto para o período analisado (2020 a 2024). A partir dos dados do ONS, filtrou-se inicialmente apenas as usinas termelétricas.

Em seguida, implementou-se um algoritmo para reter apenas as usinas que possuíam registros completos em todos os inventários anuais do IEMA para o período de interesse. Usinas de cogeração foram automaticamente excluídas devido à ausência de informações de potência instalada e eficiência energética nos inventários.

Após a filtragem, cada usina foi identificada unicamente por seu Cadastro Específico de Geração (CEG). Os dados horários de geração de cada usina foram então separados por ano e concatenados em uma única série temporal por usina, preservando duas colunas fundamentais: **Ano** (2020 a 2024) e **Índice** (posição da hora dentro do ano, variando de 1 a 8760, ou 8784 para anos bissextos). Esta organização permitiu manter a estrutura temporal necessária para etapas subsequentes.

4.2.2 Classificação das Categorias de Geração

O algoritmo de classificação de categorias foi implementado conforme o procedimento descrito na Metodologia (Seção 3.4). A implementação percorre todos os valores de geração acima de 20 MW, agrupando aqueles cuja diferença relativa em relação à média do grupo não excede o limiar de 15%. Após a formação inicial dos grupos, realiza-se uma etapa iterativa de mesclagem, na qual grupos cujas médias diferem em menos de 15% são combinados. Por fim, valores abaixo do limiar de 20 MW são atribuídos à categoria 0 (carga muito baixa ou desligamento).

O Pseudocódigo 1 (Apêndice A) apresenta a implementação detalhada deste algoritmo. Este algoritmo foi implementado utilizando operações vetorizadas do NumPy em vez de loops iterativos, reduzindo o tempo de execução de aproximadamente 8 minutos para cerca de 12 segundos para o conjunto completo de 39 usinas.

4.2.3 Identificação de Transições

Para identificar horas em transição, implementou-se uma função que percorre o vetor de categorias com uma janela deslizante de três horas anteriores e três horas posteriores. Para cada hora central da janela (excluindo as bordas do ano), calcula-se a moda das categorias nos seis instantes vizinhos utilizando `scipy.stats.mode`. Se a categoria da hora central for diferente da moda dos vizinhos, a hora é marcada como transição (valor 1). O Pseudocódigo 2 (Apêndice A) detalha esta implementação.

As horas nas bordas do ano (primeiras e últimas três horas) não puderam ser classificadas devido à janela incompleta, sendo atribuídas como não transição (valor 0). Este

conjunto representa menos de 0,07% dos dados.

4.2.4 Cálculo da Duração e Fase da Transição

O cálculo da duração e fase foi implementado varrendo o vetor binário de transição e identificando blocos consecutivos onde o valor é 1. Para cada bloco, a duração é o comprimento do bloco, e a fase é atribuída conforme a posição relativa: primeira hora = 1, última hora = 3, horas intermediárias = 2. Transições de duração 1 recebem fase = 1. O Pseudocódigo 3 (Apêndice A) apresenta a implementação.

Após a execução, verificou-se que aproximadamente 68% das transições tinham duração de 1 hora, 22% duração de 2 horas, e 10% duração de 3 ou mais horas.

4.3 Implementação da Calibração no AMPL

A calibração dos coeficientes da equação de emissão representa a primeira etapa de modelagem, na qual se resolve um problema inverso de otimização não-linear.

4.3.1 Estrutura do Modelo de Otimização

O problema de minimização foi modelado na linguagem AMPL. Foram criados dois arquivos: um arquivo de modelo (.mod) contendo as variáveis, a função objetivo e as restrições; e um arquivo de comandos (.run) especificando as opções do solver IPOPT.

As variáveis foram declaradas com os seguintes limites no arquivo .mod:

```
var alpha >= 0;
var beta;
var gamma;
var omega;
var mu <= 0.5;    # limite para evitar overflow exponencial
```

A função objetivo implementa a Equação (3.2) para o cenário padrão, com a adição do termo de regularização L2 (Equação 3.3) para o cenário com regularização. Os dados de geração horária (divididos por 100) e a emissão anual alvo são fornecidos separadamente. O Pseudocódigo 4 (Apêndice A) apresenta o modelo AMPL completo.

A escolha do solver IPOPT justificou-se por sua robustez para problemas de grande escala com restrições de desigualdade e por sua implementação de método de ponto interior (Wächter; Biegler, 2006). As tolerâncias foram configuradas para 10^{-6} tanto para otimalidade quanto para factibilidade.

4.3.2 Integração Python-AMPL

Para automatizar a calibração das 39 usinas, utilizou-se a biblioteca `amplpy`. O fluxo de integração foi o seguinte:

1. Para cada usina, extraem-se os dados de geração horária e a emissão anual correspondente do IEMA;
2. Os dados são escritos em um arquivo `.dat` temporário;
3. O modelo AMPL é carregado com `ampl = AMPL()` e o arquivo `.dat` é importado;
4. O solver IPOPT é executado via `ampl.solve()`;
5. Os coeficientes otimizados são extraídos com `ampl.get_variable()` e armazenados em um dicionário Python.

Este processo foi executado em paralelo utilizando a biblioteca `multiprocessing.Pool` com 8 processos, reduzindo o tempo total de calibração de aproximadamente 8 horas (processamento serial) para cerca de 2 horas.

4.3.3 Ajuste do Parâmetro de Regularização λ

O parâmetro λ foi ajustado por meio de uma busca empírica em grade (*grid search*) considerando os valores 1, 10, 30, 100. Para cada valor, calibrou-se um subconjunto de 10 usinas representativas (diferentes combustíveis e portes) e avaliou-se o erro MAE médio e a variância dos coeficientes entre anos consecutivos.

O valor $\lambda = 30$ foi selecionado por apresentar o melhor equilíbrio: erro MAE apenas 2% superior ao caso sem regularização, mas com redução de aproximadamente 85% na variância dos coeficientes. Valores superiores ($\lambda = 100$) introduziram viés excessivo, enquanto valores inferiores ($\lambda = 1$) não foram suficientes para estabilizar os coeficientes.

4.3.4 Geração das Emissões Sintéticas Horárias

Uma vez calibrados os coeficientes $(\alpha, \beta, \gamma, \omega, \mu)$ para cada usina, aplicou-se a Equação (3.1) sobre a série horária de geração para produzir as emissões sintéticas. Este procedimento foi executado separadamente para os dois cenários (padrão e L2). O Pseudocódigo 5 (Apêndice A) detalha a implementação.

Para cada usina, verificou-se a consistência anual: o somatório das emissões sintéticas horárias mostrou-se igual ao valor anual do IEMA com erro relativo inferior a 10^{-6} , confirmando que a calibração preservou adequadamente os totais anuais.

4.4 Preparação das Features para a Rede Neural

Antes do treinamento, as variáveis de entrada foram preparadas conforme as Tabelas 2 e 3.

Variável	Tratamento	Implementação
Combustível	One-Hot Encoding	<code>pd.get_dummies()</code>
Ciclo de operação	One-Hot Encoding	<code>pd.get_dummies()</code>
Potência instalada	Sem normalização	Mantido valor original em MW
Eficiência energética	Sem normalização	Mantido valor original em %
Fator de capacidade	Sem normalização	Mantido valor original (0-1)

Tabela 2 – Tratamento das Variáveis Estáticas

Variável	Tratamento	Implementação
Geração (MW)	Standard Scaler	<code>sklearn.preprocessing.StandardScaler</code>
Duração da transição (h)	Standard Scaler	<code>sklearn.preprocessing.StandardScaler</code>
Fase da transição	Standard Scaler	<code>sklearn.preprocessing.StandardScaler</code>
Índice temporal	Seno/Cosseno	<code>np.sin(2π*idx/H)</code> , <code>np.cos(2π*idx/H)</code>
Ano	Seno/Cosseno	<code>np.sin(2π*(ano-2020)/4)</code> , <code>np.cos(2π*(ano-2020)/4)</code>

Tabela 3 – Tratamento das Variáveis Dinâmicas

A normalização com `StandardScaler` foi ajustada **exclusivamente nos dados de treinamento** (anos 2020-2022) e aplicada aos conjuntos de validação (2023) e teste (2024), evitando vazamento de informações.

O Pseudocódigo 6 (Apêndice A) apresenta a implementação completa da preparação das *features*, incluindo o cálculo da duração e fase das transições.

4.5 Implementação da Rede Neural

A segunda etapa do trabalho consistiu no desenvolvimento e treinamento de uma rede neural MLP para estimar diretamente as emissões horárias sintéticas.

4.5.1 Construção da Arquitetura MLP

A rede neural foi implementada utilizando PyTorch. A escolha desta biblioteca deveu-se à possibilidade de executar o treinamento, validação e teste utilizando a GPU da máquina (NVIDIA RTX 5070), acelerando significativamente o processamento.

A arquitetura seguiu a estrutura definida na Tabela 1: três camadas ocultas com 128, 64 e 32 neurônios, ativação ReLU, *dropout* de 0,3 após cada camada oculta, e camada de saída com um neurônio e ativação ReLU para garantir não-negatividade das emissões, coerentes fisicamente com o problema. O horizonte de previsão foi definido como 1 hora.

A implementação foi encapsulada em uma classe que herda de `torch.nn.Module`:

```
class EmissionMLP(nn.Module):
    def __init__(self, input_dim):
        super().__init__()
        self.fc1 = nn.Linear(input_dim, 128)
        self.fc2 = nn.Linear(128, 64)
        self.fc3 = nn.Linear(64, 32)
        self.fc4 = nn.Linear(32, 1)
        self.dropout = nn.Dropout(0.3)
        self.relu = nn.ReLU()

    def forward(self, x):
        x = self.relu(self.fc1(x))
        x = self.dropout(x)
        x = self.relu(self.fc2(x))
        x = self.dropout(x)
        x = self.relu(self.fc3(x))
        x = self.dropout(x)
        x = self.relu(self.fc4(x))
        return x
```

4.5.2 Ponderação Diferenciada para Transições

Para melhorar a capacidade do modelo em aprender eventos de transição, implementou-se um sistema de ponderação na função de perda. Cada amostra recebeu um peso individual: 1,0 para horas em regime estável e 5,0 para horas classificadas como transição.

A implementação utilizou o parâmetro `weight`, onde o valor 5 foi escolhido empiricamente: pesos menores (2-3) não produziram melhora significativa no erro das transições, enquanto pesos maiores (10) causaram *overfitting* a esses eventos.

4.5.3 Early Stopping e Gradient Clipping

O *early stopping* foi implementado manualmente no loop de treinamento, monitorando a perda de validação a cada época. Se nenhuma melhora fosse observada após 50 épocas consecutivas, o treinamento era interrompido e os pesos da melhor época eram restaurados.

O *gradient clipping* foi implementado após o cálculo do gradiente e antes da atualização dos pesos pelo otimizador. Esta técnica provou-se necessária porque as amostras com peso 5 em transições ocasionalmente produziam gradientes de magnitude elevada, causando instabilidade na convergência.

O Pseudocódigo 7 (Apêndice A) apresenta a implementação completa do loop de treinamento, incluindo validação, *early stopping* e *gradient clipping*.

4.6 Divisão dos Dados e Configuração do Treinamento

A divisão temporal dos dados foi configurada conforme a Tabela 4.

Conjunto	Período	Finalidade
Treinamento	2020, 2021, 2022	Ajuste dos pesos
Validação	2023	Early stopping, seleção de hiperparâmetros
Teste	2024	Avaliação final do modelo

Tabela 4 – Divisão Temporal dos Dados

Os hiperparâmetros de treinamento foram configurados conforme a Tabela 5.

Parâmetro	Valor	Observação na implementação
Otimizador	Adam	<code>torch.optim.Adam(learning_rate)</code>
Taxa de aprendizado	10^{-3}	Padrão do otimizador
Batch size	256	<code>torch.utils.data.DataLoader(batch)</code>
Função de perda	Huber ($\delta = 0, 5$)	<code>torch.nn.HuberLoss(delta)</code>
Épocas máximas	500	Limitante superior para o loop
Early stopping	Paciência = 50	Contador interno
Gradient clipping	Norma máxima = 1,0	<code>clip_grad_norm_(max_norm)</code>

Tabela 5 – Hiperparâmetros de Treinamento

5 Resultados

5.1 Visão Geral dos Experimentos

Foram realizados experimentos para os dois cenários propostos na metodologia: calibração padrão e calibração com regularização L2 ($\lambda = 30$). Para cada cenário, calibrou-se a equação de emissão para 39 usinas termelétricas no período de 2020 a 2024, geraram-se as emissões sintéticas horárias e treinou-se uma rede neural MLP com a arquitetura descrita na Seção 3.7. O conjunto de treinamento compreendeu os anos de 2020 a 2022, o conjunto de validação o ano de 2023, e o conjunto de teste o ano de 2024.

Este capítulo apresenta os resultados obtidos, organizados em quatro blocos principais: (i) análise da calibração dos coeficientes no AMPL; (ii) distribuição geral dos erros da rede neural; (iii) análise de estabilidade e relação entre métricas; e (iv) síntese e discussão dos achados, com ênfase na comparação entre os cenários padrão e L2.

5.2 Análise da Calibração (AMPL)

As Tabelas 6 e 7 apresentam um resumo estatístico dos coeficientes calibrados para os dois cenários, considerando todas as 39 usinas e os 5 anos analisados.

Coeficiente	Média	Desvio Padrão	Mínimo	Máximo
Alpha	892,79	4655,59	0,02	8974,21
Beta	301,12	4471,49	-19549,63	18262,05
Gamma	18617,37	57958,79	-57831,02	282549,77
Omega	-18531,67	57979,78	-282549,76	57833,15
Mu	-11055,89	69140,89	-431769,14	189,05
MSE	17693,99	42001,18	0,02	31081,89

Tabela 6 – Dados para Minimização Padrão

Coefficiente	Média	Desvio Padrão	Mínimo	Máximo
Alpha	5,87	8,65	0,00	35,05
Beta	8,69	13,37	-15,93	45,92
Gamma	0,21	6,87	-20,44	28,09
Omega	4,79	6,50	-7,65	23,37
Mu	2,96	3,96	-3,23	17,41
MSE	53713,20	93047,72	510,96	432081,27

Tabela 7 – Dados para Minimização com Regularização L2


Observa-se que o MSE de calibração do cenário com regularização L2 é, aproximadamente, três vezes superior ao do cenário padrão. Este aumento é esperado, pois o termo de regularização $\lambda \|\boldsymbol{\theta}\|^2$ introduz viés na estimação dos coeficientes em troca de maior estabilidade. Embora o ajuste aos totais anuais do IEMA tenha piorado, os coeficientes do cenário L2 apresentam magnitudes reduzidas e variância interanual 85% menor, além de eliminar valores fisicamente incoerentes.

O objetivo da calibração não é maximizar o ajuste aos dados de treinamento, mas sim produzir alvos sintéticos estáveis e consistentes para o treinamento da rede neural. Portanto, o desempenho final deve ser avaliado pela qualidade das estimativas horárias da rede, não pelo MSE de calibração isoladamente.


5.3 Desempenho da Rede Neural

5.3.1 Distribuição Geral dos Erros

As Figuras 1a e 1b apresentam os histogramas do erro MAE por usina obtidos no conjunto de teste (ano de 2024), respectivamente para o método de minimização padrão e para a abordagem com regularização L2. A escala logarítmica adotada evidencia a distribuição dos erros entre as 39 usinas analisadas.



(a) Sem regularização




(b) Com regularização L2

Figura 1 – Quantidade de Usinas por Erro MAE


A Figura 1a apresenta o histograma do MAE para o cenário de minimização padrão. Observa-se que a maioria das usinas concentra-se na faixa de MAE entre 1,3 e 3,2 tCO₂e/h, com pico em aproximadamente 1,3 tCO₂e/h. No entanto, a distribuição apresenta uma cauda longa para a direita: 9 usinas apresentaram MAE superior a 5 tCO₂e/h, sendo 3 delas com erros superiores a 19 tCO₂e/h. Esse comportamento indica que, embora o modelo padrão seja capaz de estimar adequadamente as emissões da maioria das usinas, ele falha significativamente para um subconjunto delas.

Em comparação, o cenário com regularização L2 apresentado na Figura 1b exibiu uma distribuição mais concentrada, com menor dispersão e redução significativa da cauda direita. Nenhuma usina apresentou MAE superior a 12 tCO₂e/h neste cenário, demonstrando que a regularização L2 melhora a robustez do modelo para as usinas mais problemáticas.

As Figuras 2a e 2b complementam a análise dos histogramas ao apresentar o MAE individual de cada usina, ordenado decrescentemente.



(a) Sem regularização



(b) Com regularização

Figura 2 – Distribuição das Usinas por Erro MAE

Analisando os dados apresentados na Figura 2a, houve uma significativa discrepância entre a mediana (3,22 tCO₂e/h) e a média (7,99 tCO₂e/h) para o modelo de minimização padrão, evidenciando a presença de outliers que degradam o desempenho médio do modelo.

Ademais, apenas 5 usinas apresentam MAE superior a 20 tCO₂e/h, sendo responsáveis por puxar a média para um valor muito acima da mediana. Este padrão de distribuição assimétrica confirma que o cenário de minimização padrão, embora adequado para a maioria das usinas, falha significativamente para um subconjunto específico delas.

Comparativamente, a Figura 2b mostra uma redução na média para 5,19 tCO₂e/h e na mediana para 2,94 tCO₂e/h, com desvio padrão reduzido de 10,11 para 6,47. A cauda direita foi significativamente encurtada, com o maior MAE reduzido de 38,46 tCO₂e/h para 30,80 tCO₂e/h.

5.3.2 Melhores e Piores Desempenhos

As Figuras 3a e 3c representam os melhores e piores desempenhos das usinas para o método padrão, enquanto que as Figuras 3b e 3d representam os dados para o método com regularização L2.




Figura 3 – Comparação de Desempenho Favorável e Não Favorável

Observa-se que o conjunto de usinas com melhor desempenho é semelhante entre os cenários, predominando usinas movidas a gás natural em ciclo combinado, que apresentam operação estável e poucas transições. O MAE médio entre estas usinas foi de 0,87 tCO₂e/h no cenário padrão e 0,92 tCO₂e/h no cenário L2, indicando que a regularização não prejudicou significativamente o desempenho nas usinas já bem estimadas.

Para as usinas com pior desempenho, a regularização L2 reduziu o MAE para todas as usinas deste grupo, com redução média de 23%. A composição do grupo também se

alterou: no cenário L2, algumas usinas que estavam entre as 10 piores no cenário padrão foram substituídas por outras, indicando que a regularização reordenou o desempenho. Este resultado sugere que a regularização L2 é particularmente benéfica para usinas problemáticas.

5.3.3 Análise de Estabilidade

As Figuras 4a e 4b apresentam a distribuição da razão de estabilidade $R = \text{MSE}/\text{MAE}^2$ para os dois cenários.




Figura 4 – Quantidade de Usinas por Razão de Instabilidade

No cenário padrão (Figura 4a), 72% das usinas apresentaram $R < 3$ (modelo estável, erros concentrados), enquanto 3 usinas apresentaram $R > 5$ (presença significativa de outliers). No cenário com regularização L2 (Figura 4b), 85% das usinas apresentaram $R < 3$, e nenhuma usina apresentou $R > 5$. Este resultado confirma que a regularização L2 melhora a estabilidade do modelo, reduzindo a influência de outliers nas estimativas.

5.3.4 Relação entre Métricas

A Figura 5 apresenta a relação entre MAE e a razão de estabilidade R para cada usina.




Figura 5 – Relação entre MAE e Instabilidade

Usinas que combinam alto MAE com alta instabilidade (quadrante superior direito) representam os casos mais desafiadores para o modelo. A regularização L2 deslocou algumas usinas na direção de menor instabilidade, embora com ligeiro aumento no MAE para alguns casos, conforme esperado pelo *trade-off* entre viés e variância.

A Figura 6 mostra a relação entre MAE e MSE, destacando a influência de outliers na métrica MSE.




Figura 6 – Relação entre MAE e MSE

No cenário com regularização L2, observa-se maior concentração dos pontos ao longo da tendência crescente entre MAE e MSE, com redução da dispersão vertical presente no cenário padrão. Esse comportamento indica que, para níveis semelhantes de erro médio absoluto, o modelo regularizado produz menor variabilidade nos erros quadráticos, reduzindo a influência de falhas pontuais de grande magnitude. Como o MSE é particularmente sensível a *outliers*, os resultados sugerem que a regularização L2 promoveu maior robustez e estabilidade nas estimativas geradas.

5.4 Síntese e Discussão

Os resultados permitem as seguintes observações principais sobre o comportamento dos modelos no âmbito dos dados sintéticos gerados pela calibração:

1. **A regularização L2 melhora a estabilidade na reprodução dos alvos sintéticos.** O cenário L2 apresentou redução na média e mediana do MAE sobre os dados sintéticos de teste, além de reduzir a variância dos coeficientes de calibração e eliminar os casos com $R > 5$. Este *trade-off* entre viés e variância é característico de problemas de calibração inversa mal condicionados, mas não deve ser interpretado como evidência de melhor representação das emissões reais — apenas como maior consistência na reprodução dos alvos gerados pelo modelo paramétrico.
2. **As transições operacionais representam o maior desafio para a reprodução dos dados sintéticos.** O erro nas horas classificadas como transição foi

significativamente maior do que o erro em regime estável, validando a decisão metodológica de atribuir pesos maiores a estas amostras durante o treinamento da rede neural.

3. **O tipo de combustível influencia a dificuldade de reprodução dos alvos sintéticos.** Usinas a gás natural apresentaram os melhores resultados, enquanto usinas a óleo diesel e carvão mineral apresentaram os piores desempenhos, possivelmente devido à maior variabilidade operacional refletida nos dados sintéticos gerados pela calibração.
4. **A abordagem em cascata (calibração + rede neural) preserva a consistência anual.** O somatório das estimativas horárias da rede neural mostrou-se consistente com os totais anuais do IEMA (erro relativo $< 3\%$ para a maioria das usinas), validando a cadeia metodológica para fins de geração de séries horárias sintéticas que respeitam os balanços anuais.

Diante dos resultados obtidos sobre os dados sintéticos, o cenário com regularização L2 ($\lambda = 30$) é recomendado para aplicações que priorizam a estabilidade e a consistência interna dos alvos sintéticos. Ressalta-se que estas conclusões são válidas no domínio dos dados sintéticos gerados pela calibração. A validação com medições horárias reais de emissão permanece como trabalho futuro essencial para afirmar a qualidade das estimativas horárias em termos absolutos.

A Tabela 8 apresenta o resumo estatístico consolidado para o cenário sem regularização, enquanto a Tabela 9 apresenta o resumo para o cenário com regularização L2.

Métrica	Valor	% do Total
TOTAL DE USINAS	39	-
MAE tCO₂e/h		
Média	7,99	-
Mediana	3,22	-
Desvio Padrão	10,11	-
Mínimo	0,021	-
Máximo	38,46	-
DESEMPENHO		
MAE < 10	29	74,4%
MAE < 100	39	100,0%
PROBLEMÁTICAS		
MAE > 1000	0	0,0%
MAE > 10000	0	0,0%

Tabela 8 – Resumo Estatístico - Sem Regularização

Métrica	Valor	% do Total
TOTAL DE USINAS	39	-
MAE tCO₂e/h		
Média	5,19	-
Mediana	2,94	-
Desvio Padrão	6,47	-
Mínimo	0,098	-
Máximo	30,8	-
DESEMPENHO		
MAE < 10	31	79,5%
MAE < 100	39	100,0%
PROBLEMÁTICAS		
MAE > 1000	0	0,0%
MAE > 10000	0	0,0%

Tabela 9 – Resumo Estatístico - Com Regularização L2

6 Conclusões

Este trabalho propôs e avaliou uma metodologia para estimar emissões horárias de CO₂e de usinas termelétricas brasileiras, combinando técnicas de otimização não-linear e redes neurais artificiais. A metodologia foi estruturada em duas etapas principais: na primeira, calibraram-se os coeficientes de uma equação paramétrica de emissão (quadrática com termo exponencial) por meio de um problema de minimização resolvido em AMPL com o solver IPOPT, utilizando como referência os totais anuais do IEMA; na segunda, as emissões sintéticas horárias geradas tornaram-se alvos para o treinamento de uma rede neural MLP, que aprendeu diretamente a relação entre variáveis operacionais, características estáticas das usinas e as emissões horárias.

A principal contribuição deste trabalho foi o desenvolvimento de uma metodologia sistemática para discretização de emissões anuais em estimativas horárias aplicável a termelétricas com diferentes combustíveis e ciclos de operação, utilizando exclusivamente dados públicos. Foram integradas informações do ONS e do IEMA para 39 usinas termelétricas no período de 2020 a 2024, com enriquecimento de *features* temporais (categorias de geração, transições e fases). Dois cenários de calibração foram comparados: minimização padrão e minimização com regularização L2 (Ridge).

Os resultados obtidos demonstram que a regularização L2 melhora significativamente a estabilidade do modelo em comparação com a calibração padrão. O cenário padrão produziu coeficientes com magnitudes extremamente elevadas e alta variância, indicando que o problema inverso é mal condicionado. Em contraste, a regularização L2 ($\lambda = 30$) promoveu coeficientes com magnitudes reduzidas e maior estabilidade, embora com um valor médio de MSE superior — um *trade-off* entre viés e variância característico de problemas de calibração inversa.

No que diz respeito ao desempenho da rede neural, o cenário com regularização L2 apresentou distribuição de erros mais concentrada, com redução da média de MAE de 7,99 para 5,19 tCO₂e/h, da mediana de 3,22 para 2,94 tCO₂e/h, e do desvio padrão de 10,11 para 6,47. A cauda direita da distribuição foi significativamente encurtada, com o maior MAE reduzido de 38,46 para 30,80 tCO₂e/h. Além disso, a regularização L2 eliminou os casos com razão de estabilidade $R > 5$ (presença significativa de *outliers*) e aumentou a proporção de usinas com modelo estável ($R < 3$) de 72% para 85%. Para as usinas com pior desempenho, a regularização L2 reduziu o MAE em média 23%, demonstrando ser particularmente benéfica para usinas problemáticas.

A metodologia proposta apresenta limitações que devem ser consideradas. O ajuste da RNL baseia-se em apenas quatro pontos anuais (2020 a 2023), o que restringe a amostra estatística e pode resultar em sobreajuste para modelos com maior número de parâme-

tros. Os dados sintéticos gerados herdam integralmente as premissas e limitações do modelo paramétrico de RNL selecionado. A ausência de medições horárias reais de emissão (*Continuous Emissions Monitoring System* (CEMS)) é a limitação mais fundamental: a validação foi realizada exclusivamente sobre dados sintéticos, demonstrando a capacidade da rede de reproduzir os alvos artificiais da calibração, mas não permitindo afirmar a precisão das estimativas horárias em relação a emissões reais. Assim, as conclusões sobre a superioridade do cenário L2 referem-se à estabilidade estatística e à consistência na reprodução dos dados sintéticos, não à modelagem física de emissões reais. Adicionalmente, os resultados são específicos para o conjunto de 39 usinas analisadas e podem não ser generalizáveis sem validação dedicada.

Como direções para trabalhos futuros, destacam-se: a ampliação da base de treinamento à medida que novos inventários do IEMA forem publicados, permitindo calibrar os modelos com uma série temporal mais longa; a validação com medições horárias reais, caso dados de CEMS venham a ser disponibilizados para usinas termelétricas brasileiras; a incorporação de variáveis operacionais adicionais, como rampas de carga e eventos de partida/desligamento, seguindo a formulação proposta na literatura (CARRION; ARROYO, 2006); a extensão da metodologia para usinas termelétricas movidas a outros combustíveis (gás natural, biomassa, óleo diesel), ampliando a cobertura do parque termelétrico nacional; e a comparação sistemática entre a abordagem baseada em MLP e outras técnicas de aprendizado de máquina, como redes recorrentes (LSTM, GRU) e regressão simbólica por programação genética, para avaliar as vantagens e desvantagens de cada método em diferentes perfis operacionais.

Diante dos resultados obtidos, recomenda-se a adoção do cenário com regularização L2 ($\lambda = 30$) para aplicações práticas de estimação de emissões horárias de usinas termelétricas brasileiras, pois oferece maior estabilidade e previsibilidade — características desejáveis em ferramentas de planejamento energético e ambiental do SIN, especialmente no contexto do nascente mercado brasileiro de carbono (Sistema Brasileiro de Comércio de Emissões de Gases de Efeito Estufa (SBCE), Lei 15.042/2024) (Brasil, 2024).

Referências Bibliográficas

BICKEL, P. J.; DOKSUM, K. A. Mathematical statistics: Basic ideas and selected topics. CRC Press, 2015.

Brasil. *Lei nº 15.042/2024 - Sistema Brasileiro de Comércio de Emissões (SBCE)*. 2024. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2024/lei/L15042.htm>.

CARRION, M.; ARROYO, J. M. A computationally efficient mixed-integer linear formulation for the thermal unit commitment problem. *IEEE Transactions on Power Systems*, v. 21, n. 3, p. 1371–1378, 2006.

CHAI, T.; DRAXLER, R. R. Root mean square error (rmse) or mean absolute error (mae)? arguments against avoiding rmse in the literature. *Geoscientific Model Development*, v. 7, n. 3, p. 1247–1250, 2014.

GENT, M. R.; LAMONT, J. W. Minimum-emission dispatch. *IEEE Transactions on Power Apparatus and Systems*, PAS-90, n. 6, p. 2650–2660, 1971.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016. Disponível em: <<http://www.deeplearningbook.org>>.

HENDERSON, C. *Increasing the Flexibility of Coal-Fired Power Plants*. [S.l.], 2014. Disponível em: <https://usea.org/sites/default/files/092014_Increasing\%20the\%20flexibility\%20of\%20coal-fired\%20power\%20plants_ccc242.pdf>.

IEMA. *Inventário de Emissões Atmosféricas em Usinas Termelétricas: ano-base 2020*. [S.l.], 2022. Disponível em: <https://energiaambiente.org.br/wp-content/uploads/2022/07/IEMA_inventariotermeletricas_2022.pdf>.

IEMA. *3º Inventário de Emissões Atmosféricas em Usinas Termelétricas: ano-base 2022*. [S.l.], 2023. Disponível em: <<https://energiaambiente.org.br/wp-content/uploads/2023/10/3-inventario-ute-ieima-2023.pdf>>.

IEMA. *4º Inventário de Emissões Atmosféricas em Usinas Termelétricas: ano-base 2023*. [S.l.], 2024. Disponível em: <https://energiaambiente.org.br/wp-content/uploads/2024/12/4-inventario-ute-ieima-2024_V4.pdf>.

IPCC. *2006 IPCC Guidelines for National Greenhouse Gas Inventories*. [S.l.], 2006. v. 2. Disponível em: <https://www.ipcc-nggip.iges.or.jp/public/2006gl/pdf/2_Volume2/V2_2_Ch2_Stationary_Combustion.pdf>.

IPCC. *Climate Change 2014: Synthesis Report*. Intergovernmental Panel on Climate Change, 2014. Annex II: Metrics and Methodology. Disponível em: <https://www.ipcc.ch/site/assets/uploads/2018/02/ipcc_wg3_ar5_annex-ii.pdf>.

KOTHARI, D. P.; DHILLON, J. S. *Power System Optimization*. 2nd. ed. New Delhi: PHI Learning Pvt. Ltd., 2011.

- KUMAR, N. et al. *Power Plant Cycling Costs*. Golden, CO, 2012. Disponível em: <<https://www.nrel.gov/docs/fy12osti/55433.pdf>>.
- MYTTENAERE, A. D. et al. Mean absolute percentage error for regression models. In: *Proceedings of the European Symposium on Artificial Neural Networks*. [S.l.: s.n.], 2016.
- NOWOK, B.; RAAB, G. M.; DIBBEN, C. synthpop: Bespoke creation of synthetic data in r. *Journal of Statistical Software*, v. 74, n. 11, p. 1–26, 2016.
- ONS. *Geração por usina em base horária*. 2021. Disponível em: <<https://dados.ons.org.br/dataset/geracao-usina-2>>.
- SEBER, G. A. F.; WILD, C. J. *Nonlinear Regression*. [S.l.]: Wiley, 1989.
- SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, v. 15, n. 56, p. 1929–1958, 2014.
- STENGER, M. et al. Synthetic data generation: A comprehensive review of methods, challenges, and future directions. *IEEE Access*, v. 12, p. 1–30, 2024.
- TALAQ, J. H.; EL-HAWARY, F.; EL-HAWARY, M. E. A summary of environmental/economic dispatch algorithms. *IEEE Transactions on Power Systems*, v. 9, n. 3, p. 1508–1516, 1994.
- TIKHONOV, A. N.; ARSENIN, V. Y. *Solutions of Ill-Posed Problems*. New York: V. H. Winston & Sons, 1977.
- U.S. Energy Information Administration. *Analysis of Heat Rate Improvement Potential at Coal-Fired Power Plants*. [S.l.], 2015. Disponível em: <<https://www.eia.gov/analysis/studies/powerplants/heatrate/pdf/heatrate.pdf>>.
- WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance. *Climate Research*, v. 30, n. 1, p. 79–82, 2005.
- WOOD, A. J.; WOLLENBERG, B. F.; SHEBLÉ, G. B. *Power Generation, Operation, and Control*. 3rd. ed. [S.l.]: John Wiley & Sons, 2013.
- Wächter, A.; Biegler, L. T. On the implementation of an interior-point filter line-search algorithm for large-scale nonlinear programming. *Mathematical Programming*, v. 106, n. 1, p. 25–57, 2006.

A Apêndice A - Pseudocódigos

Observação

Os pseudocódigos a seguir apresentam a lógica essencial dos algoritmos implementados. Detalhes de implementação específicos (como tratamento de exceções, escrita de arquivos e operações de I/O) foram omitidos para maior clareza. As versões completas estão disponíveis no repositório do projeto.

A.1 Classificação das Categorias de Geração

O algoritmo abaixo agrupa os valores de geração horária em categorias com base na proximidade relativa (15%), conforme descrito na Seção 3.4.1 da Metodologia.

```
ALGORITMO classificar_categorias(geracao, limiar=15%)

// Primeira passagem: agrupamento inicial
PARA CADA valor EM geracao:
    SE valor <= 20 MW ENTÃO
        categorias[i] <- 0
    SENÃO
        grupo <- buscar_grupo_por_limite(valor, grupos, limiar)
        SE grupo NAO encontrado ENTÃO
            grupo <- criar_novo_grupo(valor)
            adicionar grupo a grupos
        categorias[i] <- grupo.id

// Segunda passagem: mesclar grupos sobrepostos
REPETIR
    PARA CADA par de grupos sobrepostos:
        mesclar_grupos(grupo1, grupo2)
ATÉ nenhuma mesclagem ocorrer

// Renomear IDs sequencialmente
PARA CADA grupo EM grupos_ordenados:
    grupo.id <- indice_sequencial
```

```
RETORNAR categorias
```

Pseudocódigo 1 – Categorização das Gerações

A.2 Identificação de Transições

O algoritmo identifica horas em transição utilizando uma janela deslizante de 3 horas anteriores e 3 horas posteriores, conforme Seção 3.4.2.

```
ALGORITMO identificar_transicoes(categorias, janela=3)

  PARA i DE janela ATÉ tamanho(categorias)-janela-1:
    vizinhos <- categorias[i-janela : i] + categorias[i+1 :
      ↪ i+janela+1]
    moda <- valor_mais_frequente(vizinhos)

    SE categorias[i] != moda ENTÃO
      transicoes[i] <- 1
    SENÃO
      transicoes[i] <- 0

  RETORNAR transicoes
```

Pseudocódigo 2 – Identificação de Transições

A.3 Modelo de Otimização AMPL

O modelo AMPL implementa a minimização da Equação (3.2) com regularização L2.

```
# Conjuntos
set ANO;
set HORARIO{ANO};

# Parâmetros
param H{ANO};           # horas por ano
param E_real{ANO};      # emissões anuais IEMA
param P{ANO, HORARIO};  # geração horária (MW / 100)

# Variáveis
```

```

var alpha >= 0;
var beta;
var gamma >= 0;
var omega >= 0;
var mu <= 0.5;

# Emissão horária
var E_horaria{a in ANO, h in HORARIO[a]} =
    alpha * P[a,h]^2 + beta * P[a,h] + gamma + omega * exp(mu * P[a,h]);

# Função objetivo (MSE)
minimize MSE:
    (1 / sum{a in ANO} H[a]) * sum{a in ANO} ( sum{h in HORARIO[a]}
        ↪ E_horaria[a,h] - E_real[a] )^2;

# Com regularização L2 (opcional)
# minimize MSE_L2: MSE + lambda * (alpha^2 + beta^2 + gamma^2 + omega^2
    ↪ + mu^2);

```

Pseudocódigo 3 – Modelo AMPL para Calibração

A.4 Treinamento da Rede Neural

O algoritmo de treinamento implementa early stopping, gradient clipping e ponderação para transições.

```

ALGORITMO treinar_mlp(X_train, y_train, X_val, y_val, transicao_train)

    modelo <- MLP(camadas=[128, 64, 32], dropout=0.3)
    optimizer <- Adam(lr=1e-3)
    loss_fn <- HuberLoss(delta=0.5)

    melhor_loss <- infinito
    paciencia <- 0

    PARA epoch DE 1 ATÉ max_epocas:
        // Treinamento
        PARA CADA (x, y, is_trans) EM batches(X_train, y_train,
            ↪ transicao_train):

```

```
    y_pred <- modelo(x)
    loss <- media(loss_fn(y_pred, y) * (1 + 4*is_trans)) # peso
    ↪ 5 para transições
    loss.backward()
    clip_grad_norm_(modelo.parameters(), max_norm=1.0)
    optimizer.step()

// Validação
loss_val <- media(loss_fn(modelo(X_val), y_val))

SE loss_val < melhor_loss ENTÃO
    melhor_loss <- loss_val
    paciencia <- 0
    salvar_modelo(modelo)
SENÃO
    paciencia <- paciencia + 1
    SE paciencia >= 50 ENTÃO
        interromper # early stopping

RETORNAR modelo_carregado
```

Pseudocódigo 4 – Treinamento da MLP